

İNSAN ETKİNLİĞİ TANIMA VE SINIFLANDIRMA

Emirhan BOZKURT

emr.bozkurt@gmail.com

Özet

İnsanlar üzerinden istenildiği anda insan aktivitelerini sınıflandırma ve tanıma sistemleri ile bilgi elde edilebilmektedir. Bu sistemler hastalıkların tespiti, fizik tedavi aşamalarında, akıllı ev projeleri gibi farklı alanlarda kullanılmaktadır. Bu çalışmada akıllı telefonlardaki ivme ölçer ve jiroskop sensörlerinden elde edilmiş açık kaynak bir veri kümesinden alınan veriler kullanılmıştır. SVM, Karar ağacı ve Lojistik regresyon modelleri tekrarlayan sinir ağı olarak hem zaman serileri için ilişki elde edebilmesi hem de katmanlar halinde kullanılabilen esnek yapısı nedeniyle oldukça uygun bir derin öğrenme yaklaşımıdır. Bu altyapıyı içeren derin öğrenme tabanlı yaklaşım çalışmamızdaki deney için seçilmiş 30 adet farklı insanın hareketleri ,insan aktivitelerinin sınıflandırılmasında kullanılmıştır. Deneylerde farklı girdi parametreleri, katman ve ağ birimleri ilgili ağ modellerine verilerek sınıflandırma başarımları doğruluk oranı ölçülmüştür. Sonuçta yaklaşık %84 ilâ %95 arasında sınıflandırma başarımları elde edilerek altı farklı sınıfın yüksek doğrulukta sınıflandırıldığı gösterilmiştir.

Anahtar Kelimeler: İnsan Aktiviteleri, Derin Öğrenme, SVM, Karar ağacı, Lojistik regresyon

Abstract

Information can be obtained through human activities classification and recognition systems at any time. These systems are used in different areas such as the detection of diseases, physical therapy stages, smart home projects. In this study, data from an open source dataset obtained from accelerometer and gyroscope sensors on smart phones were used. SVM, Decision tree and Logistic regression models are a very suitable deep learning approach because of its flexible structure that can be used in layers as well as obtaining relationships for time series as iterative neural networks. The deep learning-based approach, which includes this infrastructure, was used in the classification of human activities, the movements of 30 different people selected for the experiment in our study. In the experiments, different input parameters, layers and network units were given to the relevant network models and the accuracy of

classification was measured. As a result, it has been shown that six different classes can be classified with high accuracy, with a classification performance of approximately 84% to 95%.

Keywords: Human Activities, Deep Learning, SVM, Decision tree, Logistic regression

1 Giriş

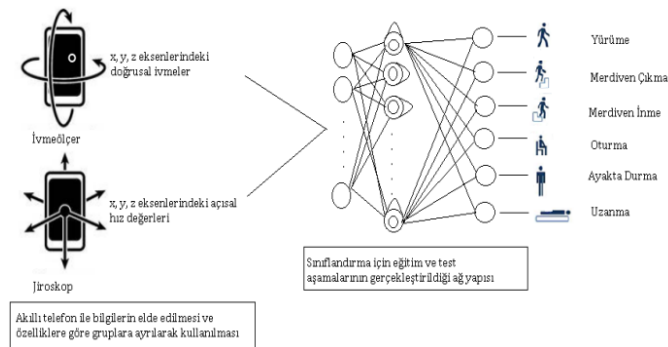
Sürekli gelişmekte olan teknolojiye, insanların bilgisayarlar ile olan bağlılığının çoğalması sebebiyle İnsan Aktivitelerinin sınıflandırılması araştırma konuları arasında önemli hale gelmiştir. [1]. Yapılan çalışmalarda İnsan Aktivitelerinin Tanınması ile insan davranışları konusunda bilgi edinmek ve gerekli alanlarda kullanımı amaçlanmıştır. Hareket tanıma veriler genellikle dış ortam duyarga cihazlarından ya da giyilebilir duyargalar (wearable sensors) tarafından elde edilirler. İvme duyargaları kullanımlarının ve ulaşımın kolay oluşu, ölçüm sonuçlarında sayısal değer alınabiliyor olması, maliyetlerinin uygun olduğu ve günlük hayatta kullanılabilirliği bu cihazları ortam duyargalarına göre daha ön planda tutulmasını sağlamıştır [2]. Toplanan bilgilerin sonrasında makine öğrenmesi algoritmaları ile işlenerek olayların tanımlanması yapılmaktadır. İnsan aktivitelerinin sınıflandırılması; hastalık teşhisi, rehabilitasyon tedavi süreci, fizik tedavi uygulama alanları, akıllı ev sistemlerinin projelendirilmesi, ortam koşullarının iyileştirilmesi ve otomatikleştirilmesi gibi birçok alanda kullanılmaktadır [3, 4]. Projeye bakıldığı zaman insan aktivitelerin sınıflandırılması konusunda farklı makine öğrenmesi yöntemleri ve duyargalar kullanıldığı görülmektedir. İnsan vücuduna yerleştirilen üç eksenli ivmeölçer ile uzanma, koşma, yürüme ve ayakta durma aktivitelerinin sınıflandırılması konusunda yüksek doğruluk oranı ile başarımlar sağlandığı görülmektedir [5]. Farklı bir çalışmada ise ayakta durma, yürüme, koşma, merdiven inme, merdiven çıkma, temizlik yapma, dış fırçalama ve oturma olarak adlandırılan sekiz eylemin değişik yöntemler ile sınıflandırmalarındaki doğruluk performansları değerlendirilmiştir [6]. Bu çalışmada, üç eksenli ivmeölçer

ve jiroskop içerisinde bulunan bir akıllı telefon verileri ile derin öğrenme mimarisi modelleri olan SVM, Karar ağacı, Lojik regresyon aracılığıyla insan aktivitelerinin sınıflandırılması yaklaşımı geliştirilmiştir. İvmeölçer verisi olarak açık kaynak bir veri kümesi kullanılmıştır.

2 İnsan Aktivitesi Algılama

2.1 İnsan Aktivitesi

İnsan aktivitesi sınıflandırma uygulaması, insanlardan elde edilen veriler ile içerisinde bulunulan çevrenin tanımlanmasıyla gerçekleştiriliyor olan hareketin belirtilmesini hedefler [7]. Bu sayede kişi hakkında istenildiğinde bilgi elde edilebilir. İnsan hareketleri genel olarak; kısa aktiviteler, temel olaylar ve karmaşık olaylar olmak üzere üç ana gruba ayrılmaktadır. Kısa aktiviteler olarak isimlendirilen hareketlere örnek verilecek olursa; uzanma pozisyonundan diğer bir pozisyona geçiş olarak adlandırılabilirken, merdiven çıkmak ise temel bir aktivitedir [8]. Farklı nesne ve bireylerin de içerisinde bulunduğu hareketler ise karmaşık hareketlerdir [9]. Araba kullanmak ve çeşitli spor hareketleri karmaşık aktivite grubuna örnekler [10]. Bu projede temel aktiviteler grubu içerisinde yer alan hareketlerin kategori edilmesi gerçekleştirilmiştir. Bu aktivite grubu içerisinde 6 temel hareket tespit edilmiştir. Bunlar; uzanma, ayakta durma ve oturma aktivitelerini içerisinde barındıran üç tane statik aktivite ile merdiven inme, merdiven çıkma ve yürüme aktivitelerini barındıran üç adet de dinamik aktiviteyi içermektedir [11]. Gerçekleştirilen yapının temel açıklaması Şekil 1’de gösterilmektedir.




Şekil 1. İnsan aktivitesi sınıflandırma altyapısı [12]

Akıllı telefonlar içerisinde ivmeölçer ve jiroskop yer almaktadır bunlar insan aktivitesi sınıflandırılması için çoğunlukla tercih edilir [13]. Telefon içerisinde 3-eksenli ivmeölçer ile 3-eksenli jiroskopun bulunduğu açısal ölçüm duyargası yer almaktadır. Aktivitenin doğrusal ivme değerini ivmeölçer, eksen etrafında dönmesinden ortaya çıkan açısal hızı ise jiroskop ölçmektedir.

2.2.1 İvmeölçer İvmeölçer

3-eksen boyunca kullanılan cihazın maruz kaldığı ivmenin ölçülmesini sağlar. 3-eksenli ivmeölçerin etki ettikleri yönler Şekil 2’de gösterilmektedir [14]. İvmelenme bilgileri zaman değerleri ile birlikte oluşmaktadır. Bu değer m/s² türünde bir veridir. Bu duyargaların sundukları veriler gerçekimi kuvveti ve doğrusal ivmedir [15].




Şekil 2. İvmeölçer algılayıcısı

2.2.2 Jiroskop

Aktivite sınıflandırılmasında yön tayini ve değişikliklerinin belirlenmesinde kullanılan giyilebilir duyargalardan jiroskop Şekil 3’te görüldüğü üzere x, y, z eksenlerinde elde edilen açısal hız değerlerini belirtmektedir. Belirtilen fiziksel eksenler etrafında dönme hareketi rad/s (radyan/saniye) türünden gösterilmektedir [16].

2.2 Giyilebilir Duyargalar




Şekil 3. Jiroskop algılayıcısı

3 İnsan Aktivitelerini Sınıflandırma

Projede gerçekleşen sistemlerin incelenmesi sonrasında insan aktivitelerinin sınıflandırılması için ortam duyargaları ve giyilebilir cihazlardan elde edilen duyarga bilgilerinin makine öğrenmesi teknikleri kullanılarak çıkarım yaptığı gözlemlenmektedir. Bu bölümde çalışmada kullanılan SVM, Karar ağacı, Lojistik regresyon gibi derin öğrenme yöntemlerinden bahsedilmiştir.

3.1 SVM

Sınıflandırma veya Regresyon problemleri için kullanılabilen denetimli bir makine öğrenmesi algoritmasıdır. Bununla birlikte, çoğunlukla sınıflandırma problemlerinde kullanılır. Bu algoritmada, her bir veri maddesini belirli bir koordinatın değeri olan her özelliğin değeri ile birlikte n-boyutlu boşluğa (burada n sahip olduğunuz özelliklerin sayısı) bir nokta olarak çizilir. Ardından, iki sınıftan oldukça iyi ayırım yapan hiperdüzlemi kullanarak sınıflandırma gerçekleştirilir [17].



Şekil 4 Destek Vektör Makinesi grafik

3.2 Lojistik Regresyon

Lojistik modelin biyolojik deneylerin analizi için kullanımı ilk olarak Berkson (1944) tarafından önerilmiş, Cox (1970) bu modeli gözden geçirerek çeşitli uygulamalarını yapmış, özet gelişmeler ise ilk Andersson (1979, 1983) tarafından verilmiştir. Ayrıca verilerin lojistik modele uyumu ile ilgili birçok çalışmalar da yapılmıştır. Bunlar arasında Aranda-Ordaz (1981) ve Johnson(1985) tarafından yapılan çalışmalar en önemlileridir. Pregibon (1981) iki grup lojistik modelde etkin (influential), aykırı (outlier) gözlemleri ve belirleme ölçütlerini (diagnostic), Lesaffre (1986), Lesaffre ve Albert (1989) ise çoklu grup lojistik modellerde etkin ve aykırı gözlemlerle belirleme ölçütlerini incelemişlerdir [18].

3.3 Karar Ağacı

Karar ağacı, bir kurum veya kuruluş tarafından tercihlerin, risklerin, kazançların ve hedeflerin anlaşılmasına yardımcı olan bir teknik türüdür. Aynı zamanda birçok önemli yatırım sahalarında uygulanabilen, birbiriyle bağlantılı şans olaylarıyla ilgili olarak çıkan çeşitli karar noktalarını incelemek için kullanılan bir karar destek aracıdır. Yalnızca koşullu kontrol ifadeleri içeren bir algoritmayı görüntülemenin bir yoludur.

Karar ağacı, bir hedefe ulaşma olasılığı en yüksek olan stratejiyi belirlemeye yardımcı olmak için kullanılan bir yöntemidir. Özellikle karar analizinde olmak üzere karmaşık sorunların araştırmasında yaygın olarak kullanılmaktadır. Ayrıca makine öğrenmesinde kullanılan yaygın bir araçtır [19].

4 Uygulama

4.1 Veri Kümesi

Projede kullanılan duyarga verileri, açık kaynak veri kümesi olan UCI veri kümesi deposundan alınmıştır [20, 21]. Verilerin elde edilme deneylerinde 30 kişinin bellerine ivme ölçer ve jiroskop verileri bulunan akıllı telefon takılarak sınıflandırılması yapılacak 6 aktivitenin yapılması gerçekleştirilmiştir. Bunlar İngilizce terimleriyle birlikte sırayla; “Walking (Yürüme)”, “Walking Upstairs (Merdiven çıkma)”, “Walking Downstairs (Merdiven inme)”, “Sitting (Oturma)”, “Standing (Ayakta durma)”, “Laying (Uzanma)” olarak veri kümesinde etiketlenmişlerdir. İvmeölçer ve Jiroskop duyargaları kullanılarak üç eksenli doğrusal gövde ile yerçekimi ivmeleri (tAcc – XYZ) ve üç eksenli açısal hız (tGyro – XYZ) sinyalleri elde edilmiştir. Bu duyarga sinyalleri gürültü filtreleri uygulanarak ön işleme tabi tutulur ve daha sonra her biri 50 Hz. frekansında 2.56 saniyelik sabit genişlikli pencerelerde örneklenmektedir. Her pencerede 128 okuma gerçekleştirilmektedir. Elde edilen normalize edilmiş 9 sinyal verisine (“body_acc_x_”, “body_acc_y_”, “body_acc_z_”, “body_gyro_x_”, “body_gyro_y_”, “body_gyro_z_”, “total_acc_x_”, “total_acc_y_”, “total_acc_z_”) 17 farklı öznelik fonksiyonu (‘mean()’, ‘mad()’, ‘max()’, ‘sma()’ vb...) uygulanarak 561 öznelikten oluşan bir öznelik vektörü oluşturulmuştur. Bu vektördeki verilerin normalize edilmesi gerekmiştir. Vektör değerleri [-1, 1] aralığı için normalize edilmiştir. Deneylerdeki 30 kişiden elde edilen toplam 10299 verinin %70 ‘i olan 7352 adet veri eğitim için, 2947 veri ise %30 ‘luk kalan kısım olarak test için kullanılmıştır [21].

4.2 Deneysel Sonuçlar

Projedeki çalışmada geliştirilen uygulama, derin öğrenme alt yapısını oluşturmak için Python [22] programlama dili kullanılarak geliştirilmiştir. Bu işlemler için bir Python dilini destekleyen Google Colab platformu kullanılmıştır [23]. Colab online bir platform olduğundan derin öğrenme mimarileri için gerekli birçok kütüphaneyi ve Python programlama diline dair ek yüklemelerine gerek kalmamıştır. Yapılan deneylerde şu tipte parametreler; eğitim yineleme sayısı, girdi verilerinin parçalar halinde işleme alınacağı boyut (Mini-Batch), çıktı birim sayısı, girdi birim sayısı, adım zaman (timestep) başına verilen giriş parametresi ve aktivasyon fonksiyonu kullanılmıştır.

SONUÇ	HEDEF	YÜRÜME	MERDİVEN ÇIKMA	MERDİVEN İNME	OTURMA	AYAKTA DURMA	UZANMA
YÜRÜME		489	3	4	0	0	0
MERDİVEN ÇIKMA		4	462	4	1	0	0
MERDİVEN İNME		6	23	391	0	0	0
OTURMA		0	1	0	359	125	6
AYAKTA DURMA		1	0	0	31	500	0
UZANMA		0	0	0	0	0	537

Tablo 1 Karmaşıklık Matrisi

Tablo 1 ‘de sınıflandırılma çalışması yapılan 6 insan aktivitesinin SVM karmaşıklık matrisi yer almaktadır. Belirtilen matriste satır değerleri test edilen modelin gerçek sınıf aktivite sayılarını belirtmektedir. Sütun verileri ise tahmin edilen sınıf aktivite sayılarını belirtmektedir. Uzanma (537) ve ayakta durma (500) aktiviteleri için oldukça iyi sınıflandırma yapıldığı görülmektedir. Projede ki çalışmaların çoğu yapay sinir ağı modeli zaman serilerinin işlenmesine dayanan daha yüksek seviyeli öznelikler ve bunların aralarındaki ilişkileri çözümleyememektedir.

5 Sonuç

Bu çalışmada akıllı telefonların içerisinde yer alan ivmeölçer ve jiroskop verilerinin toplanması ile oluşturulmuş veri kümesi ile oluşturulan 6 insan aktivitesinin sınıflandırılması için eğitim ve testleri gerçekleştirilmiştir. Bu testlerde SVM %93,07, Karar ağacı %85,81 ve Lojik regresyon ise %94,04 puan ile en yüksek başarımları almıştır. Lojik regresyon diğer yapay sinir ağları ile kıyaslandığında en yüksek skor olarak ön plana çıkmıştır.

Kaynaklar

- [1] Chen Y, Shen C. “Performance analysis of smartphone-sensor behavior for human activity recognition”. IEEE Access 5, 3095–3110, 2017.
- [2] Yang M, Zheng H, Wang H, McClean S, Newell D. “iGAIT: An interactive accelerometer based gait analysis system”. Computer Methods and Programs in Biomedicine, 108:715-723, 2012.
- [3] Avci A, Bosch S, Marin-Perianu M, Marin-Perianu R, Havinga P. “Activity recognition using inertial sensing for healthcare, well being and sports applications: A survey”. 23rd International

Conference on Architecture of Computing Systems (ARCS), pp. 1-10, VDE 2010.

[4] Lin W, Sun M.-T, Poovandran R, Zhang Z. "Human activity recognition for video surveillance". IEEE International Symposium on Circuits and Systems, 2737-2740, 2008.

[5] Yang J.-Y, Wang J.-S, Chen Y.-P. "Using acceleration measurements for activity recognition: An effective learning algorithm for constructing neural classifiers". Pattern Recognition Letters, 29(16), 2213-2220, 2008.

[6] Ravi N, Dandekar N, Mysore P, Littman M.L. "Activity recognition from accelerometer data". AAAI, 5, 1541-1546, 2005.

[7] Wang J, Chen R, Sun X. "Generative models for automatic recognition of human daily activities from a single triaxial accelerometer". WCCI 2012 IEEE World Congress on Computational Intelligence, 10- 15, June 2012.

[8] Bao L, Intille S.S. "Activity recognition from userannotated acceleration data". Pervasive Computing, 1-17, 2004.

[9] Aggarwal K.K, Ryoo M.S. "Human activity analysis: A review". ACM Computing Surveys, 43 (3), 1-16, 2011.

[10] Reyes-Ortiz J.L, Oneto L, Sama A, Parra X, Anguita D. "Transition-Aware Human Activity Recognition Using Smartphones", Neurocomputing, Volume 171 Issue C, Pages 754-767, January 2016.

[11] Bao L, Intille S.S. "Activity recognition from userannotated acceleration data". Pervasive Computing, 1-17, 2004.

[12] Tural K, Akdoğan E. "Akıllı Telefonların Algılayıcılarının Verilerini Kullanarak Yapay Sinir Ağları ile İnsan Hareketlerinin Sınıflandırılması". Otomatik Kontrol Ulusal Toplantısı TOK, cilt.1, no.1, ss.479-483, İstanbul, Türkiye, 21-23 Eylül 2017.

[13] Reyes-Ortiz J.L, Oneto L, Ghio A, Sama A, Anguita D, Parra X. "Human Activity Recognition on Smartphones with Awareness of Basic Activities and Postural Transitions". Artificial Neural Networks and Machine Learning, ICANN, Lecture Notes in Computer Science. 8681, 177-184, Springer 2014.

[14] Su X, Tong H, Ji P. "Activity Recognition with Smartphone Sensors". Tsinghua Science and Technology, International Journal of Information Science, vol. 19, no. 3, pp. 235-249, 2014.

[15] Sağbaş E.A, Ballı S. (2015) Akıllı Telefon Sensörlerinin Kullanımı ve Ham Sensör Verilerine Erişim. Akademik Bilişim, 158-164, Eskişehir, Türkiye, 4-6 Şubat 2015.

[16] Gunduz H, Cataltepe Z. "Borsa İstanbul (BIST) daily prediction using financial news and balanced feature selection". Expert Systems with Applications, 42(22), 9001-9011, 2015.

[17] <https://veribilimcisi.com/2017/07/19/destek-vektor-makineleri-support-vector-machine/>

[18] <https://dergipark.org.tr/tr/download/article-file/252030>

[19] https://tr.wikipedia.org/wiki/Karar_a%C4%9Fac%C4%B1

[20] UCI veri kümesi websitesi. "Human Activity Recognition Using Smartphones Data Set". <https://archive.ics.uci.edu/ml/datasets/human+activity+recognition+using+smartphones>.

[21] Anguita D, Ghio A, Oneto L, Parra X, Reyes-Ortiz J.L. "A Public Domain Dataset for Human Activity Recognition Using Smartphones". ESANN proceedings, European Symposium on Artificial Neural Networks, Computation a Intelligence and Machine Learning. Bruges (Belgium), 24-26 April 2013, i6doc.com public, ISBN 978-2-87419-081-0. http://www.i6doc.com/en/livre/?GCOI=28001100_131010.

[22] Python programlama dili websitesi. <https://www.python.org/>.

[23] <https://colab.research.google.com/notebooks/>